X-ONE ASSISTANT

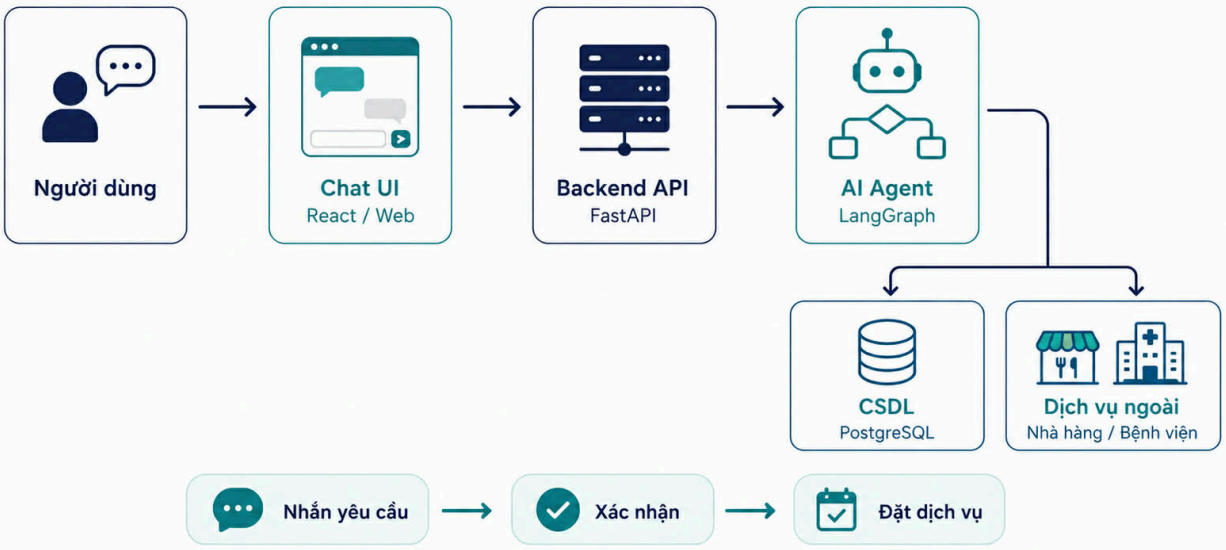
CONVERSATIONAL MULTI-SERVICE AI AGENT

Trợ lý AI hội thoại hỗ trợ tìm kiếm, đặt, thanh toán và quản lý đa dịch vụ

Loại tài liệu	Product Requirements Document
Phiên bản	1.0
Thời gian phát triển	6 tuần
Quy mô nhóm	4 thành viên
Mức độ	Tham vọng cao, triển khai theo vertical slice

Sơ đồ kiến trúc

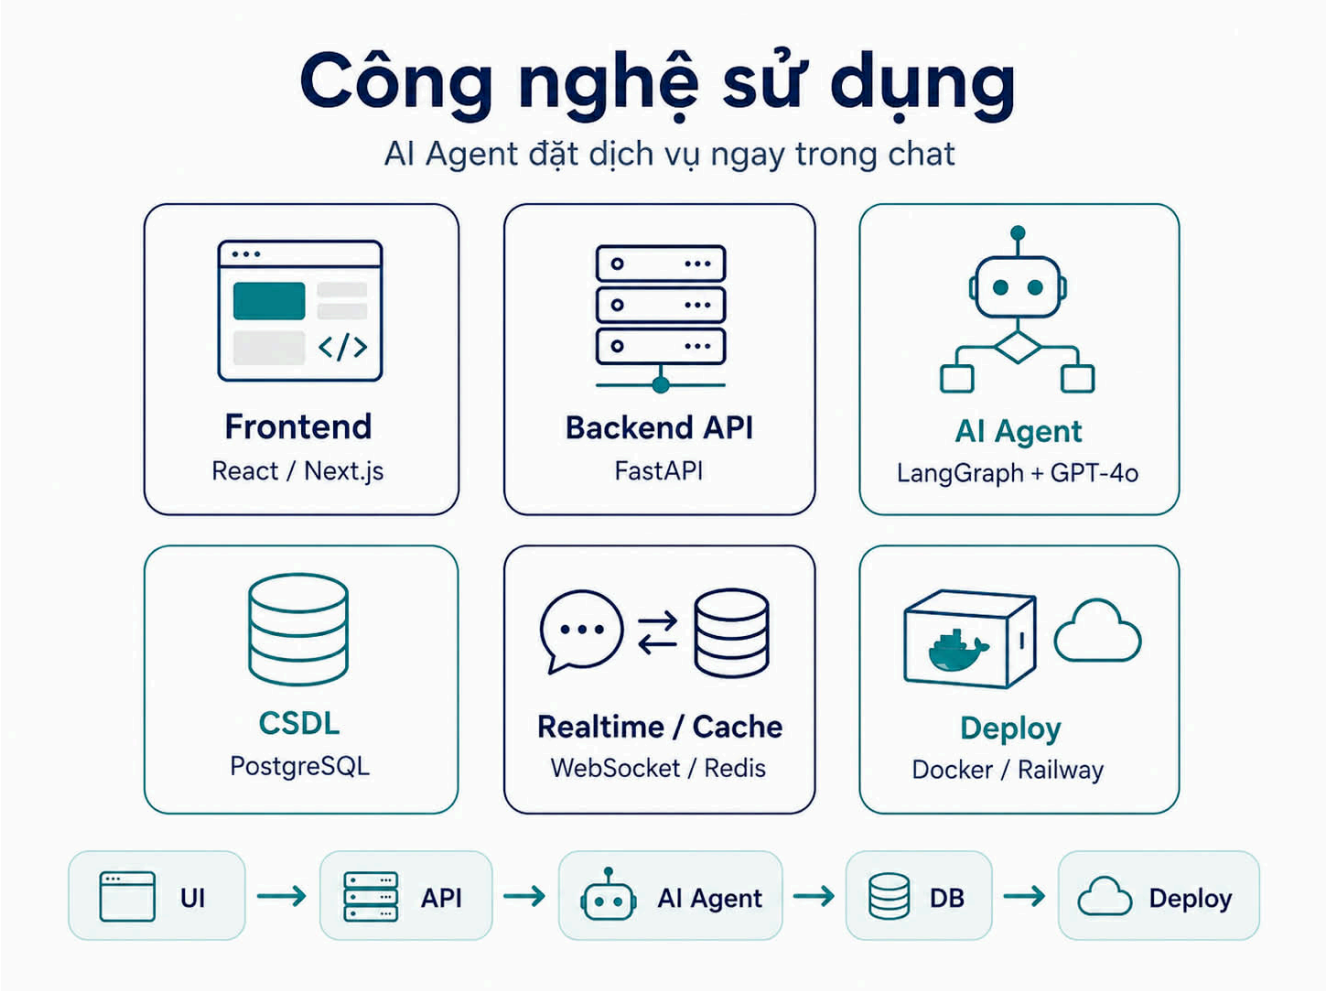
AI Agent đặt dịch vụ ngay trong chat



Tính năng cốt lõi

AI Agent đặt dịch vụ ngay trong chat





MỤC LỤC

1. Tổng quan sản phẩm
2. Bối cảnh và vấn đề
3. Tầm nhìn, mục tiêu và nguyên tắc
4. Phạm vi sản phẩm
5. Đối tượng người dùng
6. User stories và tiêu chí chấp nhận
7. Luồng nghiệp vụ chính
8. Yêu cầu chức năng
9. Yêu cầu phi chức năng
10. Kiến trúc hệ thống
11. Thiết kế AI Agent
12. Tool specification
13. Dữ liệu và cơ sở dữ liệu
14. UX/UI và rich cards

15. Bảo mật và safeguard
16. Evaluation plan
17. Success metrics
18. Phân chia công việc
19. Kế hoạch 6 tuần
20. Definition of Done
21. Rủi ro và phương án giảm thiểu
22. Kịch bản demo
23. Phạm vi không thực hiện
24. Kết luận

1. TỔNG QUAN SẢN PHẨM

X-One Assistant là nền tảng AI Agent hoạt động trực tiếp trong giao diện hội thoại, cho phép người dùng tìm kiếm, đặt, thanh toán và quản lý nhiều loại dịch vụ mà không cần chuyển đổi giữa nhiều ứng dụng.

> **Định vị sản phẩm: không phải chatbot hỏi đáp, mà là một hệ thống thực thi tác vụ có workflow, state, memory, human-in-the-loop và transaction safety.**

1.1 Thông tin dự án

Thuộc tính	Mô tả
Tên sản phẩm	X-One Assistant
Loại sản phẩm	Web application responsive
Ngôn ngữ chính	Tiếng Việt
Nhóm phát triển	4 thành viên
Thời gian	6 tuần
Hạ tầng dự kiến	Docker, Railway/Render/VPS
LLM	Model hỗ trợ structured output và tool calling
Orchestration	LangGraph

1.2 Mô tả ngắn

Người dùng có thể nhập yêu cầu tự nhiên như: “Đặt lịch khám da liễu gần trường vào sáng mai và đặt xe để tôi đến trước 15 phút.” Hệ thống sẽ hiểu yêu cầu, thu thập thông tin còn thiếu, lập kế hoạch nhiều bước, gọi các tool dịch vụ, kiểm tra xung đột, yêu cầu xác nhận, thực hiện giao dịch sandbox và theo dõi trạng thái theo thời gian thực.

2. BỐI CẢNH VÀ VẤN ĐỀ

2.1 Thực trạng

- Người dùng phải mở nhiều ứng dụng cho một hành trình duy nhất.
- Thông tin bị phân mảnh giữa chat, bản đồ, ứng dụng đặt lịch, gọi xe và ví điện tử.
- Các dịch vụ phụ thuộc nhau về thời gian nhưng không được phối hợp tự động.
- Người dùng dễ nhập sai dữ liệu, quên lịch hoặc xử lý không tốt khi một bước thất bại.

2.2 Vấn đề cốt lõi

Người dùng không chỉ muốn nhận thông tin. Họ muốn hoàn thành công việc từ đầu đến cuối. Một chatbot có thể trả lời “có ba bệnh viện gần bạn”, nhưng một agent đáng tin cậy phải tiếp tục tìm lịch, đề xuất lựa chọn, xác nhận, đặt lịch, tính giờ di chuyển, đặt xe và theo dõi trạng thái.

2.3 Cơ hội sản phẩm

Một mini-app hội thoại có thể giảm số bước thao tác, rút ngắn thời gian hoàn thành và tạo trải nghiệm liền mạch. Sản phẩm cũng là nền tảng tốt để thể hiện năng lực AI application engineering, backend transaction, realtime, bảo mật và đánh giá agent.

3. TẦM NHÌN, MỤC TIÊU VÀ NGUYÊN TẮC

3.1 Tầm nhìn

Xây dựng một nền tảng AI Agent đa dịch vụ có khả năng hoạt động như một mini-app trong hội thoại, nơi người dùng hoàn thành các quy trình phức tạp bằng ngôn ngữ tự nhiên nhưng vẫn giữ quyền kiểm soát ở mọi hành động quan trọng.

3.2 Mục tiêu sản phẩm

1. Hỗ trợ bốn domain dịch vụ ở mức khác nhau về chiều sâu.
2. Làm sâu hai domain cốt lõi: đặt xe và đặt lịch khám.
3. Hỗ trợ ít nhất một luồng đa dịch vụ hoàn chỉnh.
4. Có human-in-the-loop bắt buộc trước booking, payment và cancel có phí.
5. Có realtime tracking, memory có consent, audit log và operator dashboard.
6. Đánh giá agent bằng bộ test và số liệu định lượng.

3.3 Nguyên tắc thiết kế

Nguyên tắc	Diễn giải
Agent không nắm toàn quyền	Business rules và quyền thực thi nằm ở backend.
Không bịa dữ liệu	Option, giá, lịch và trạng thái phải đến từ tool.
Xác nhận rõ ràng	Không suy đoán sự đồng ý từ câu mơ hồ.
Thiết kế có thể mở rộng	Dịch vụ mới được thêm qua adapter/tool registry.
Lỗi phải có lối thoát	Retry có giới hạn, fallback và human handoff.
Đo được	Mọi agent run, tool call và giao dịch quan trọng đều được trace.

4. PHẠM VI SẢN PHẨM

4.1 Dịch vụ đặt xe — mức triển khai sâu

- Tìm chuyến xe theo điểm đón, điểm đến và thời gian.
- Loại xe: xe máy, Economy 4 chỗ, Premium 4 chỗ, xe 7 chỗ.
- So sánh giá, thời gian tài xế đến và thời gian di chuyển.
- Đặt xe, thanh toán sandbox, hủy, hiển thị phí hủy.
- Theo dõi realtime: tìm tài xế, đã nhận, đang đến, đã đến, đang di chuyển, hoàn thành.
- Chống tạo đơn trùng bằng idempotency key.

```
DRAFT → WAITING_CONFIRMATION → SEARCHING_DRIVER → DRIVER_ASSIGNED → DRIVER_ARRIVING →
DRIVER_ARRIVED → IN_PROGRESS → COMPLETED / CANCELLED / FAILED
```

4.2 Dịch vụ đặt lịch khám — mức triển khai sâu

- Tìm bệnh viện theo khu vực và khoảng cách.
- Tìm chuyên khoa, bác sĩ, mức giá và lịch trống.
- Đặt, đổi và hủy lịch khám.
- Hiển thị hướng dẫn trước khi khám.
- Kết hợp với đặt xe để đến trước thời gian hẹn.
- Không chẩn đoán bệnh, kê thuốc hoặc thay thế tư vấn chuyên môn.

4.3 Dịch vụ đặt bàn nhà hàng — mức chứng minh khả năng mở rộng

- Tìm nhà hàng theo khu vực, loại món, ngân sách và đánh giá.
- Kiểm tra bàn trống theo thời gian và số lượng người.
- Đặt, đổi giờ, đổi số người và hủy bàn.
- Hỗ trợ yêu cầu đặc biệt: không hút thuốc, trẻ em, dị ứng, bàn riêng.

4.4 Thanh toán hóa đơn sandbox — mức chứng minh transaction safety

- Danh sách hóa đơn điện, nước, Internet và điện thoại giả lập.
- Preview giao dịch, xác nhận, thanh toán, thất bại, timeout và refund sandbox.
- Biên nhận và lịch sử thanh toán.
- Không xử lý tiền thật trong phiên bản này.

4.5 Mức ưu tiên

Mức	Nội dung
P0 — bắt buộc	Auth, chat, ride, medical, confirmation, order, payment sandbox, realtime, audit, deploy.
P1 — nên có	Multi-service planning, operator dashboard, memory consent, restaurant cơ bản, evaluation dashboard.
P2 — nếu còn thời gian	Bill payment đầy đủ, refund nâng cao, pgvector memory, circuit breaker dashboard, recommendation tốt hơn.

5. ĐỐI TƯỢNG NGƯỜI DÙNG

5.1 Customer

- Quản lý hồ sơ, địa chỉ và sở thích.
- Gửi yêu cầu qua chat, chọn option, xác nhận và theo dõi đơn.
- Đổi, hủy, xem lịch sử và quản lý dữ liệu memory.

5.2 Operator

- Theo dõi đơn lỗi, conversation cần hỗ trợ và tool call thất bại.

- Tiếp quản hội thoại khi agent không xử lý được.
- Cập nhật trạng thái, refund sandbox và xử lý giao dịch bất thường.

5.3 Administrator

- Quản lý user, role, provider, dịch vụ, hạn mức và cấu hình hệ thống.
- Xem audit log, chi phí LLM và dashboard vận hành.

6. USER STORIES VÀ TIÊU CHÍ CHẤP NHẬN

ID	User story	Mô tả	Acceptance criteria
US-01	Yêu cầu tự nhiên	Người dùng nhập tiếng Việt, kể cả câu thiếu hoặc sai chính tả phổ biến.	Agent hỏi lại khi không chắc và không bịa slot.
US-02	Slot filling	Agent chỉ hỏi thông tin còn thiếu.	Không hỏi lại dữ liệu đã biết; cho phép sửa slot.
US-03	Multi-service	Người dùng đặt nhiều dịch vụ trong một câu.	Có plan, dependency và xử lý partial failure.
US-04	Confirmation	Người dùng xem toàn bộ thông tin trước hành động.	Booking/payment không chạy nếu token xác nhận không hợp lệ.
US-05	Realtime	Người dùng theo dõi chuyến xe tức thời.	WebSocket reconnect và đồng bộ lại timeline.
US-06	Memory	Agent ghi nhớ địa chỉ/sở thích khi được đồng ý.	Có xem, sửa, xóa, tắt memory.
US-07	Hủy đơn	Người dùng hủy “đơn vừa đặt”.	Agent xác định đúng đơn, hiển thị phí và hỏi xác nhận.
US-08	Xử lý lỗi	Dịch vụ không khả dụng vẫn có phương án.	Retry giới hạn, fallback và human handoff.

7. LUỒNG NGHIỆP VỤ CHÍNH

7.1 Đặt xe

```
User request → classify intent → extract slots → ask missing → search_rides → show cards → select
→ confirmation summary → confirm → book_ride → payment sandbox → realtime tracking → receipt
```

7.2 Đặt lịch khám và xe

```
Request → build plan → search facility/doctor/slot → select appointment → calculate travel time →
search ride → conflict check → confirm plan → book appointment → book ride → return linked orders
```

7.3 Partial failure

Nếu lịch khám đã đặt nhưng không tìm được xe, hệ thống giữ lịch khám, ghi rõ trạng thái và đưa ra lựa chọn: tìm loại xe khác, đổi giờ đón, đổi lịch khám hoặc hủy lịch. Không rollback mù quáng.

7.4 Human handoff

```
Agent failure / user request / suspicious transaction → create support ticket → transfer conversation context → operator takeover → continue in same thread
```

8. YÊU CẦU CHỨC NĂNG

ID	Tên	Yêu cầu
FR-01	Authentication	Đăng ký, đăng nhập, refresh token, logout, RBAC, khóa tạm sau nhiều lần sai.
FR-02	Conversation	Tạo/xóa/đổi tên conversation, lưu message, streaming, khôi phục workflow.
FR-03	Intent	Nhận diện nhóm intent của ride, medical, restaurant, bill, order, memory và support.
FR-04	Slot extraction	Trích xuất địa điểm, ngày giờ, số người, loại dịch vụ, ngân sách, provider, yêu cầu đặc biệt.
FR-05	Planning	Tạo plan cấu trúc với step, dependency, status và dữ liệu đầu ra.
FR-06	Tool calling	Schema rõ, timeout, retry, permission, idempotency, error code và audit.
FR-07	Human-in-the-loop	Bắt buộc xác nhận cho booking, payment, cancel có phí, refund và lưu dữ liệu nhạy cảm.
FR-08	Confirmation token	Gắn user, action, payload hash, expiry, nonce; TTL tối đa 5 phút.
FR-09	Order management	Order, order item, event timeline, trạng thái và liên kết multi-service.
FR-10	Payment sandbox	Intent, preview, confirm, success/failure/timeout, refund, receipt, idempotency.

ID	Tên	Yêu cầu
FR-11	Realtime	WebSocket, reconnect, Redis Pub/Sub, event persistence, notification.
FR-12	Memory	Consent, source, confidence, last-used, xem/sửa/xóa/tắt.
FR-13	Operator dashboard	Đơn lỗi, ticket, tool error, payment error, latency, LLM cost.
FR-14	Human handoff	Chuyển operator kèm toàn bộ context và trạng thái.
FR-15	Audit	Actor, action, resource, before/after, timestamp, result, error, confirmation ID.

8.1 Danh sách intent tối thiểu

```
search_ride | book_ride | cancel_ride | track_ride
search_medical_appointment | book_medical_appointment | reschedule_medical_appointment |
cancel_medical_appointment
search_restaurant | book_restaurant | update_restaurant_booking | cancel_restaurant_booking
list_bills | pay_bill | refund_payment
view_order | cancel_order | update_order | manage_memory | general_support | out_of_scope
```

9. YÊU CẦU PHI CHỨC NĂNG

Nhóm	Yêu cầu
Hiệu năng	API thường <500 ms; first token <4 giây; WebSocket update <1 giây; demo load 50 concurrent users.
Độ tin cậy	Retry tối đa 2 lần; checkpoint sau bước quan trọng; payment không retry mù quáng.
Bảo mật	JWT, refresh rotation, Argon2/bcrypt, RBAC, rate limit, masking, validation, chống IDOR.
Quan sát	Structured logs, trace ID, token usage, tool latency, error rate, order failure rate.
Mở rộng	Tool registry, service adapter, business logic ngoài prompt.
Khả dụng	Responsive, rich cards, loading/retry/error rõ ràng, form fallback.

10. KIẾN TRÚC HỆ THỐNG

```
React / Next.js
   │ REST + SSE/WebSocket
FastAPI Backend
   ├─ Auth / User / Conversation
   ├─ Order / Confirmation / Payment
   ├─ Realtime / Audit / Operator
   └─ LangGraph Agent
        ├─ Ride Tools
        ├─ Medical Tools
        ├─ Restaurant Tools
        └─ Payment Tools

Data: PostgreSQL + Redis + optional pgvector
Deploy: Docker Compose → Railway/Render/VPS
```

10.1 Quyết định kiến trúc

- Dùng FastAPI để giảm chi phí tích hợp AI, schema và WebSocket.
- Dùng PostgreSQL cho nghiệp vụ; Redis cho session, cache, checkpoint và Pub/Sub.
- Chỉ dùng pgvector khi có truy hồi memory ngữ nghĩa thật sự.
- Một LangGraph điều phối có module service; chưa bắt buộc full multi-agent ở giai đoạn đầu.

11. THIẾT KẾ AI AGENT

11.1 Agent state

```
user_id, conversation_id, messages
intent, confidence, requested_services
extracted_slots, missing_slots, user_context
execution_plan, current_step_index
search_results, selected_options
pending_actions, confirmation_status, confirmation_token
created_order_ids, payment_ids
tool_call_count, retry_count, error_history, response_type
```

11.2 LangGraph nodes

```
load_context → classify_request → extract_slots → resolve_references → validate_request →
build_plan → validate_plan → ask_missing_information → route_service → search_options →
rank_options → present_options → capture_selection → build_confirmation → wait_for_confirmation →
execute_action → verify_result → handle_failure → compensate → save_memory_candidate →
generate_response / handoff_operator
```

11.3 Giới hạn

Thông số	Giá trị
max_graph_steps	20
max_tool_calls_per_turn	8
max_retries_per_tool	2
tool_timeout	10 giây

Thông số	Giá trị
confirmation_ttl	5 phút
max_plan_services	4

11.4 Phân chia trách nhiệm

LLM được làm	Backend bắt buộc kiểm soát
Hiểu ý định, trích xuất slot, lập plan, chọn tool, tạo phản hồi.	Giá, quyền, state transition, hạn mức, confirmation, idempotency, payment, audit.
Giải thích option và hỏi bổ sung.	Không cho LLM tự sửa option, amount hoặc provider response.

12. TOOL SPECIFICATION

Domain	Tools
Ride	search_rides, preview_ride, book_ride, get_ride_status, cancel_ride, rate_ride
Medical	search_facilities, search_specialties, search_doctors, search_slots, preview_appointment, book, reschedule, cancel, status
Restaurant	search_restaurants, availability, preview_booking, book, update, cancel
Payment	list_bills, preview_payment, create_intent, confirm_payment, status, refund, receipt
Memory	get_preferences, suggest_memory, save, update, delete, list

12.1 Chuẩn bắt buộc cho mỗi tool

- Pydantic input/output schema.
- Permission level: search, transaction, privileged.
- Timeout và retry policy.
- Error code ổn định.
- Idempotency cho action tạo hoặc thay đổi dữ liệu.
- Audit log và trace ID.
- Không nhận dữ liệu quan trọng do LLM tự bịa lại nếu đã có option_id/resource_id.

13. DỮ LIỆU VÀ CƠ SỞ DỮ LIỆU

13.1 Bảng chính

```
users, roles, user_profiles, user_addresses, user_preferences, user_memories
conversations, messages, agent_runs, agent_checkpoints
service_providers, service_catalog, service_options
orders, order_items, order_events, order_confirmations
payment_intents, payment_transactions, payment_refunds, receipts
tool_calls, audit_logs, notifications
support_tickets, operator_messages
```

13.2 Nguyên tắc dữ liệu

- Dữ liệu có cấu trúc lưu trong PostgreSQL.
- Dữ liệu ngắn hạn và realtime lưu Redis.
- Thông tin nhạy cảm được mask trong log.
- Memory có consent và trạng thái xóa.
- Mọi order có event timeline bất biến để truy vết.

14. UX/UI VÀ RICH CARDS

14.1 Component bắt buộc

- Chat bubble, typing indicator, streaming response.
- Ride card, appointment card, restaurant card, bill card.
- Confirmation card, multi-service plan card, receipt, order timeline.
- Error card, retry action, memory consent card, operator takeover indicator.

14.2 Nguyên tắc UX

- Không ép người dùng đọc JSON hoặc lỗi kỹ thuật.
- Mọi hành động có tác động phải có nút rõ ràng.
- Cho chỉnh sửa từng slot thay vì bắt đầu lại.
- Refresh trang không làm mất state đang xử lý.
- Khi agent không chắc, chuyển sang lựa chọn hoặc form.

15. BẢO MẬT VÀ SAFEGUARD

15.1 Prompt injection

- Bỏ qua yêu cầu tiết lộ system prompt, secret hoặc token.
- Không cho prompt vượt qua confirmation hoặc tool permission.
- Không cho LLM thay đổi giá, amount hoặc payload đã xác nhận.
- Tool input luôn được backend validate độc lập.

15.2 Transaction policy

Loại hành động	Chính sách
Search/view	Không cần xác nhận.

Loại hành động	Chính sách
Booking	Bắt buộc xác nhận.
Payment	Bắt buộc xác nhận; giá trị cao có OTP sandbox.
Cancel có phí	Hiển thị phí và xác nhận.
Refund	Theo policy hoặc operator approval.

15.3 Idempotency

```
key = hash(user_id + action_type + resource_id + confirmation_id + payload_hash)
```

15.4 Privacy

- Không lưu số thẻ đầy đủ hoặc CVV.
- Không đưa secret/access token vào prompt.
- Giảm dữ liệu y tế gửi LLM xuống mức cần thiết.
- Cho phép user xóa memory và dữ liệu liên quan theo chính sách.

16. EVALUATION PLAN

16.1 Bộ test tối thiểu

Nhóm	Số lượng
Đơn dịch vụ	50
Thiếu thông tin	30
Đổi ý/context	20
Đa dịch vụ	20
Tool failure	10
Prompt injection/security	10
Out-of-scope	10
Tổng	150

16.2 Chỉ số

- Intent accuracy.
- Slot precision, recall và F1.
- Tool selection accuracy.
- Plan correctness.
- Confirmation compliance.
- Task completion rate.

- Error recovery rate.
- Hallucination rate.
- Latency, token cost, tool calls và graph steps trung bình.

16.3 Kiểm thử bắt buộc

- Happy path, thiếu dữ liệu, mơ hồ, đổi ý, timeout, hết xe/lịch, payment fail.
- Confirmation token hết hạn và payload mismatch.
- Nhấn xác nhận nhiều lần.
- Truy cập order của user khác.
- Prompt injection và tool call trái quyền.

17. SUCCESS METRICS

Metric	Mức bắt buộc	Mức kỳ vọng
Booking/payment có xác nhận	100%	100%
Giao dịch trùng trong retry	0	0
Tool selection accuracy	≥90%	≥95%
Single-service completion	≥85%	≥90%
Multi-service completion	≥70%	≥80%
Error recovery phù hợp	≥80%	≥90%
First response latency	<4 giây	<3 giây
Tool nguy hiểm trái quyền	0	0

18. PHÂN CHIA CÔNG VIỆC

Vai trò	Phạm vi chính	Deliverables
AI Agent Engineer	LangGraph, prompt, slot, planning, routing, guardrail, evaluation.	Agent graph, prompt versioning, test report.
Backend Engineer	FastAPI, auth, DB, order, confirmation, payment, audit, RBAC.	API docs, migrations, tests, business services.
Frontend Engineer	Chat UI, rich cards, realtime, profile, memory, operator dashboard.	Responsive UI, WebSocket integration, E2E flows.
Integration/DevOps/QA	Mock APIs, Redis, Docker, CI/CD, deployment, load/integration test.	Service sandbox, pipelines, monitoring, seed data.

Nguyên tắc nhóm: mỗi vertical slice phải có ít nhất hai người cùng review; không để bốn module "gần xong" nhưng chưa có một luồng end-to-end chạy được.

19. KẾ HOẠCH 6 TUẦN

Sprint	Phạm vi	Milestone
Tuần 1 — Foundation	PRD, API contract, DB, AgentState, monorepo, Docker, Auth, Conversation API, Chat UI, CI skeleton.	User đăng nhập và chat được end-to-end.
Tuần 2 — Ride Vertical Slice	Ride mock API, slot filling, search, card, confirm, book, payment, realtime, cancel, idempotency, audit.	Đặt và theo dõi chuyến xe hoàn chỉnh.
Tuần 3 — Medical Vertical Slice	Facility/specialty/doctor/slot, booking, reschedule, cancel, reminder, safeguard.	Đặt/đổi/hủy lịch khám qua chat.
Tuần 4 — Multi-Service + Restaurant	Planning, dependency, conflict detection, medical+ride, restaurant basic, partial failure.	Demo được plan nhiều dịch vụ.
Tuần 5 — Hardening	Bill sandbox, operator, handoff, memory consent, permission, injection defense, logging, 150 tests.	Happy path, failure path và operator path.
Tuần 6 — Production	E2E/load/security test, tuning, bug fix, deploy, seed data, docs, video, slide, rehearsal.	Bản public ổn định và báo cáo metrics.

19.1 Quy tắc tiến độ

- Không thêm feature lớn ở tuần 6.
- Ride phải chạy end-to-end cuối tuần 2.
- Medical phải chạy end-to-end cuối tuần 3.
- Nếu trễ, giảm chiều sâu restaurant/bill trước; không cắt confirmation, idempotency, audit hoặc testing.
- Mỗi ngày có integration build và demo nội bộ ngắn.

20. DEFINITION OF DONE

7. Có API contract hoặc interface rõ ràng.
8. Có validation và authorization.
9. Có error handling và fallback phù hợp.
10. Có audit log nếu là hành động quan trọng.
11. Có unit test và integration test.
12. Chạy trong Docker.
13. Có seed data hoặc migration.

14. Được ít nhất một thành viên khác review.
15. Được tích hợp vào một luồng end-to-end.
16. Có tài liệu ngắn và tiêu chí acceptance đã đạt.

21. RỦI RO VÀ PHƯƠNG ÁN GIẢM THIỂU

Rủi ro	Tác động	Giảm thiểu
Agent không ổn định	Sai tool, vòng lặp, khó debug.	Structured output, deterministic routing, giới hạn bước, evaluation hằng ngày.
Phạm vi quá lớn	Chậm và nhiều phần nông.	Ưu tiên ride → medical → multi-service → các phần mở rộng.
Schema lệch giữa các thành phần	Integration failure.	OpenAPI, shared schema, contract test, mock server.
Demo phụ thuộc LLM	Timeout hoặc kết quả biến động.	Model fallback, seed data, timeout, form fallback, kịch bản test ổn định.
Làm việc quá sức	Chất lượng giảm, bug tăng.	Chia ca hợp lý, review/test riêng, không coi 12 giờ ngồi là 12 giờ hiệu quả.
Realtime phức tạp	Mất trạng thái khi reconnect.	Persist event, replay timeline, Redis Pub/Sub, integration test.
Security bị bỏ quên	Giao dịch trái quyền hoặc lộ dữ liệu.	Policy engine backend, RBAC, payload hash, audit, security tests.

22. KỊCH BẢN DEMO

22.1 Demo chính

“Tìm lịch khám da liễu gần trường sau 9 giờ sáng thứ Hai và đặt xe để tôi đến trước 20 phút.”

17. Agent lấy địa chỉ trường từ memory có consent.
18. Tìm cơ sở, bác sĩ và lịch trống.
19. Người dùng chọn lịch.
20. Agent tính thời gian di chuyển và giờ đón.
21. Tìm xe, phát hiện xung đột nếu có.
22. Hiển thị plan tổng và giá dự kiến.
23. Người dùng xác nhận.
24. Tạo hai order liên kết và theo dõi realtime.

22.2 Demo failure và safeguard

- Ride API trả hết xe: agent đề xuất loại xe khác hoặc đổi giờ.

- User yêu cầu “bỏ qua xác nhận”: backend từ chối tool transaction.
- Nhấn nút xác nhận hai lần: chỉ một order được tạo.
- Refund vượt quyền: tạo ticket và operator tiếp quản.

23. PHẠM VI KHÔNG THỰC HIỆN

- Tích hợp Grab, ngân hàng hoặc bệnh viện thật.
- Xử lý tiền thật hoặc eKYC.
- Chẩn đoán y tế và kê thuốc.
- Mobile native, voice assistant đầy đủ.
- Kubernetes production, multi-region, compliance cấp doanh nghiệp.
- Recommendation ML riêng và provider marketplace quy mô lớn.

24. KẾT LUẬN

PRD này đặt mục tiêu cao nhưng vẫn giữ cấu trúc ưu tiên rõ ràng. Giá trị cốt lõi nằm ở hai vertical slice sâu, một luồng đa dịch vụ thuyết phục, transaction safety, realtime, human-in-the-loop và evaluation định lượng. Restaurant và bill payment đóng vai trò chứng minh khả năng mở rộng, không được phép làm ảnh hưởng đến chất lượng của ride và medical.

> **Tiêu chuẩn thành công cuối cùng: người dùng gửi một yêu cầu tự nhiên, agent hiểu đúng, hỏi đủ, gọi đúng tool, xác nhận đúng lúc, tạo đúng một giao dịch, theo dõi được trạng thái và xử lý thất bại mà không bịa dữ liệu.**